

个人项目运行展示

项目一：WeightMind - 科研文献 RAG 智能问答引擎


1. 项目背景：

针对科研论文场景中大语言模型容易产生事实幻觉的问题，本项目确立了“精准溯源原文”的产品方向，通过构建不同领域的论文 RAG 知识库，并对论文进行精细拆分与标签化，使用户在问答时能够精准定位相关内容，从而提升大模型回答的准确性与可信度。

2. 项目位置与网址：

- a) Github: <https://github.com/HuaxiaHuang/WeightMind>
- b) 网站: <http://weightmind.chat> (注：目前并未备案，域名尚不可用，可通过腾讯云后台地址访问：<http://42.194.201.78:8501/>)

3. 前端网站页面展示：



网站主要有两个功能：新建会话以及知识库管理，前者主要与用户进行交互，回答用户的问题；而后者则是接收用户所上传的文档，传到后端进行解析以及向量化。

a) 页面展示：

i.上传论文（知识库管理）：



ii.会话功能（新建会话）：



b) 结果展示：

i.会话：

帮我写一个关于赤潮暴发原因的综述文章大纲

✓ 惟明引擎 思考与检索路径...

点击查看溯源文献及片段

注：当前本地文献库中未检索到充分的直接证据，此部分分析基于通用科学常识补充。

赤潮暴发原因综述文章大纲

1. 引言

- 定义赤潮：赤潮是指海洋中某些浮游生物（主要是甲藻类、硅藻类等）在特定条件下爆发性增殖或聚集，导致水体变色的一种生态异常现象。
- 赤潮的危害：包括鱼类和贝类的大规模死亡、食物链破坏、经济损失以及对人类健康的威胁（如通过贝类毒素引发中毒）。
- 研究意义：系统梳理赤潮暴发机制，为监测预警与生态管理提供理论支持。

2. 环境驱动因素

- 营养盐富集（富营养化）：氮、磷等营养物质的过量输入是赤潮发生的关键前提，主要来源于农业径流、城市污水排放和水产养殖废水 [通用常识]。
- 水文气象条件：适宜的水温、光照强度、盐度及水体层化稳定状态有利于赤潮藻类的生长与聚集 [通用常识]。
- 气候变化影响：全球变暖延长了赤潮发生的季节窗口，极端天气事件可能加剧营养盐输入频率和强度 [通用常识]。

3. 生物内在机制

- 赤潮物种的竞争优势：部分赤潮藻具有快速吸收营养的能力、抗逆性强、能产生抑制其他微生物的化学物质（化感作用）等特性 [通用常识]。
- 种群遗传多样性与微多样性的作用：尽管本地文献未直接讨论赤潮藻类，但研究表明微生物种群内部存在显著的遗传异质性（microdiversity），这种微多样性可增强种群适应环境变化的能力，提高其在波动环境中的生存与扩张潜力 [4, Discussion, 第10段关于微多样性与适应性的论述]。
- 菌株水平的演化动态：高分辨率宏基因组分析工具（如InStrain）能够检测共享菌株并揭示原位进化过程，提示赤潮优势种可能存在快速适应性突变或优势克隆扩散现象 [3, Results, 第39

从输出的结果来看，WeightMind 既融合了常规大语言模型的分析回答，又结合文献库中根据向量相似度匹配度最高的文献进行补充说明（红色箭头标记不同来源的信息）。

在“惟明引擎 思考与检索路径”中记录的是后台在接收到问题后的处理过程（如下图），一步步报告目前所进行的任务，以减少用户等待的枯燥。而在“点击查看溯源文献及片段”中，则记录的是跟用户问题最匹配的文章、对应的段落以及相似度计算，增加可信度。

赤潮主要受什么影响

惟明引擎 思考与检索路径...

已接收问题，正在唤醒 RAG 检索管线...

收到指令，正在唤醒惟明（WeightMind）混合检索管线...

正在调用大模型进行跨学科领域路由分析...

领域锁定：将精准检索 [environmental_science, biology] 库。

正在推理 HyDE（假设性文档嵌入）以弥合语义鸿沟...

生成假设答案项 “赤潮（有害藻华）的爆发机制是一个涉及多尺度环境因子耦合的复杂过程。现有研究表明，水体富营养化尤其是氮磷负荷的异常升高是诱发赤潮的首要外源性驱动力，且促进了藻类...”

正在激活 BGE-M3 模型，将假设内容转化为高维向量矩阵...

正在 Qdrant 中并行执行 Dense(稠密) + Sparse(稀疏) 混合语义检索...

领域 environmental_science 触发智能降级，正在执行纯稠密向量检索...

领域 biology 触发智能降级，正在执行纯稠密向量检索...

浅层切分完成，跨领域共召回 20 个可能相关的文档块。

正在调用底层 BGE-Reranker 对候选文档进行极致的交叉注意力重排...

深度重排完成，已精准剥离噪音，保留 Top 5 个核心论点。

正在执行父块溯源，为碎片化片段恢复完整的论文上下文语境...

检索管线全部执行完毕！正在融合知识生成最终科研解答...

检索完成！成功在 [environmental_science, biology] 领域匹配到 3 个高相关度文档块。

正在将知识融合，生成最终回答...

4. 后端运行逻辑：

a) 接收论文与向量库的构建

i.文件的防重与信息记录：后端接收到前端上传的论文后，首先进行哈希防重校验拦截，接着通过 PyMuPDF 快速扫描并提取论文首页的标题、作者、DOI 号、期刊等元信息。随后接入 Crossref 的 API 进行论文信息的核对，经过初步去重、检验确认后，记录到 PostgreSQL 中。最后调用 LlamaParse /TextIn 的 API 对论文解析成 Markdown 格式。

ii.父子块切分与向量化：基于 Markdown 文件进行按照设定的标点符号（句号、问号等）和 Token 长度进行滑动切分子块，对切出来的子块进行章节坐标与父块 ID 等元信息的记录，对子块进行向量化后存入 Qdrant 中。

b) 提问与检索

当后端接收到用户的提问后，首先进行 HyDE 策略，由 LLM 生成预答文本并向量化。接着在 Qdrant 中进行稠密向量和稀疏向量的双路比对，选取相似度前五的子块。最后利用子块所标记的父块 ID，去文档库拉取包含完整上下文的父块，整合后喂给 LLM，最后融合输出带有真实引用内容的回答。

项目二：智搜考公助手小程序 demo


1. 项目背景：

当前考公类应用普遍重资讯分发、轻咨询服务，用户面对海量报名信息难以获得个性化指导。针对这一痛点，基于官方公务员考试报名信息搭建 RAG 知识库，使大模型能够依据真实数据提供精准信息查询与个性化报考指导。

2. 项目位置：

a) 目前仅本地调试运行

3. 小程序运行展示：



从最终的测试效果来看，本项目已经能够基于既有资料进行查阅与作答。由于当前阶段爬虫仅配置了“国家公务员局”网站的监控，尚未抓取其他省份的报考信息，所以本项目目前专精于解答国考相关问题，对于其他省份的报考信息并未进行捏造。

4. 后端运行逻辑：

- a) **监测与文件获取：**系统基于 APScheduler 实现定时任务调度，每日爬取政府网站公告列表并计算哈希值判断更新。新增文件会被下载并存储，同时生成 metadata.json，记录标题、来源 URL、发布日期等信息，为后续解析和可溯源设计提供支持。
- b) **文件清洗与解析，向量化入库：**通过 cleaner.py 模块完成文本清洗，包括编码修复、空白与换行归一化、冗余噪声删除，以及垂直领域关键信

息抽取（如招考人数、报名时间等）。使用 `prepare_chunks_for_rag` 将清洗后的文本切分为带重叠的滑动窗口块，并注入标题、来源、关键实体等元信息。将每个文本块调用 `Embedding` 模型进行向量化，并存入 `Qdrant`，为 RAG 检索提供基础。

- c) **检索与问答：**用户提问后，系统将问题向量化，并与向量库计算余弦相似度以检索最相关的文本块，将检索结果和 `Prompt` 整合后输入大模型，生成带有可溯源文献信息的精准回答。

5. 问题分析：

当前这个小程序的数据主要依赖网页抓取。但是各政府单位的底层架构以及反爬虫机制复杂多变，若靠人工挨个写代码去识别并获取信息，工作量大且鲁棒性差，所以目前仅接入了“国家公务员局”的数据，暂未向其他省市单位的网站进行拓展。